

Laboratorio 8

Nombre	Carné
Daniel Chet	231177
Cristian Túnchez	231359
Javier Linares	231135

Task 1 - Mini-GPT a nivel de carácter

Task 1.1 - Pipeline de datos

Se descargó `tiny_shakespeare`, se construyó un vocabulario ordenado de exactamente 65 caracteres y se definieron los mappings carácter-a-índice e índice-a-carácter. El texto se codificó como enteros y se dividió 90%/10% conservando el orden temporal.

Hiperparametro	Valor
block size	128
d model	128
n heads	4
n layers	3
batch size	64
learning rate	$3e^{-4}$
epochs	10
split	90% y 10%

Cada batch tiene forma 64 por 128. Para una secuencia x , el objetivo y se construye como el mismo fragmento desplazado un carácter: y en t corresponde a x en t más uno. Una aserción comprueba esta relación antes del entrenamiento.

Arquitectura entrenamiento y perplejidad

El modelo decoder only suma embeddings de token y posición, usa tres bloques Transformer con cuatro cabezas y aplica una máscara triangular superior. La salida en cada posición solo depende del prefijo disponible.

Época	Train loss	Validation loss	Tiempo acumulado en segundos
1	2.9947	2.6340	110.9
2	2.5678	2.5155	220.8
3	2.4935	2.4556	331.3
4	2.4389	2.3995	442.0
5	2.3711	2.3180	553.0
6	2.2947	2.2337	664.1
7	2.2215	2.1632	775.9
8	2.1608	2.1137	886.2
9	2.1050	2.0730	997.0
10	2.0615	2.0360	1108.6




Figura 1. Pérdidas de entrenamiento y validación durante las 10 épocas.

Perplejidad final

7.650. La evaluación cubrió 111,539 de 111,539 targets de validación, por lo que N corresponde a todo el split evaluable. El resultado está dentro del intervalo esperado de 3.5 a 8.0.

$$\text{Perplejidad} = \exp\left(\frac{1}{N} \sum_{t=1}^N L_t\right)$$

Estrategias de muestreo

Estrategia	Implementación
Greedy	Selecciona argmax de cada logit y no contiene aleatoriedad
Top k	Divide logits entre tau, conserva exactamente k índices, aplica softmax y muestrea
Top p	Ordena probabilidades, forma el núcleo mínimo de masa p, renormaliza y muestrea

La implementación valida que tau sea positiva, que k esté entre 1 y el tamaño del vocabulario y que p esté en el intervalo abierto por la izquierda y cerrado por la derecha entre 0 y 1. También prueba un empate en el umbral de top k para garantizar que nunca se conserven más de k candidatos.

Task 2

Muestras generadas

Configuración	Estrategia	Parámetros
A	greedy	sin parámetros adicionales
B	top k	k igual a 5 y tau igual a 0.7
C	top k	k igual a 50 y tau igual a 1.0
D	top p	p igual a 0.70 y tau igual a 0.7
E	top p	p igual a 0.95 y tau igual a 1.0

Configuración A Greedy

```
=====
Config A – greedy {}
=====

--- muestra 1 ---
ROMEO:
What the the the the the so so so the the the sone
And the shat the so the the the stere the the the she so son
The shat the the shat the the she so she the so sone the so sone
The shat the the she s

--- muestra 2 ---
ROMEO:
What the the the the the so so so the the the sone
And the shat the so the the the stere the the the she so son
The shat the the shat the the she so she the so sone the so sone
The shat the the she s

--- muestra 3 ---
ROMEO:
What the the the the the so so so the the the sone
And the shat the so the the the stere the the the she so son
The shat the the shat the the she so she the so sone the so sone
The shat the the she s

--- muestra 4 ---
ROMEO:
What the the the the the so so so the the the sone
And the shat the so the the the stere the the the she so son
The shat the the shat the the she so she the so sone the so sone
The shat the the she s

--- muestra 5 ---
ROMEO:
What the the the the the so so so the the the sone
And the shat the so the the the stere the the the she so son
The shat the the shat the the she so she the so sone the so sone
The shat the the she s
```

Configuración B Top k con k 5 y tau 0.7

```
=====
Config B - top_k {'k': 5, 'tau': 0.7}
=====

--- muestra 1 ---
ROMEO:
There stere so the some a and a ther the thou ser
I me the and hall a dower that the so the with sood,
And be shavers the shat that the som my sto stry thime
That hor the anger have shour a trume the

--- muestra 2 ---
ROMEO:
Thou he thou be see seardeards of mor sinters
Whis staress a that stright thy her sone so my
Thingst to he the artises to bat hat a the my an and
till the the to he anes madices the that hars singe
W

--- muestra 3 ---
ROMEO:
And that that he the stresss be of sters,
Thou dend ser, that so shard heave all to me.

CUTER:
And mord my son the so hice she and mon the her a strom mest
Ther me sears and he he sorse to to my so

--- muestra 4 ---
ROMEO:
And to the seare to the a a me then a to to man to some
And the sup and to so marntliting the be and
That thou mang the sthe to she as me the sears my
That mer shise me that senter he as offore and
A

--- muestra 5 ---
ROMEO:
What sto thou hat that sher at hal the sof thou dither
As bet ond sell of my martione sore art sontere.

PELLINCENCENTER:
What hord mance stare the sher sone share and mond were the
What she the shan
```

Configuración C Top k con k 50 y tau 1 0

```
=====
Config C – top_k {'k': 50, 'tau': 1.0}
=====

--- muestra 1 ---
ROMEO:
Pet swat this be fork'd col trove hey ne love
Sine of lit. Cty pactee hews, and come'tur woulf ist
goughYis merearmen to to adood atiziontant.

BONGBEMIORK:
AyF rep hat the thau by torciaze de my bla

--- muestra 2 ---
ROMEO:
CaRLTIAs thy hou trasty thight tate shy.

TICILLO:
BacI leartincestve tran though. Cherncelf.
Wo sevem, Maricd is you he
wey ond minicat hatess seer. Bay magim tho thiss
Ha this he us be ruse do'd le

--- muestra 3 ---
ROMEO:
And shand the a and meforty intllor,
The is lonecegeran, bory likentshand whepend,
not ther pransie, sesthrser'd; Ands sows rear that my to you
Son ing do beneast---'llem ante, the theneme
Whare youm

--- muestra 4 ---
ROMEO:
O, he tay, 'll comn I kim comstince thes argood,
Wou of by gret Ropeeposet? thue of wild.

GRUTILIO:
Wall be I bye perpees beactole ard wick,
Torrotind cand offeree clake olly,'s you your way.

Crme:

--- muestra 5 ---
ROMEO: my me breike.

MESTARIO:
Hy my.
Thaly will as fair cle offeme, vige, these eim lare!

FOUTARK:
A be I's spiensom will I sarruped move hat foien?

Nonetirensen:
Thym held Math.
Whee bush it thistign, t
```

Configuración D Top p con p 0.70 y tau 0.7

```
=====
Config D - top_p {'p': 0.7, 'tau': 0.7}
=====

--- muestra 1 ---
ROMEO:
No that will stard my and word the deater that his bes of she
The and with our and my that that be the surese there
Here heare com stall of in she his and he the so be
Whe as the a that my be dome he

--- muestra 2 ---
ROMEO:
The so would be and the of in be of the come and ther
And his songe that me a deart that wou me bellant,
And may that my that the can the of hear mess be he my far my
The the sond and but of the be a

--- muestra 3 ---
ROMEO:
What his me me the so my the my all sto the beesere stee of martin
That is the the the prie of be the be and so she beere the so my his fater
The the he he the an of him buch the an the and the some

--- muestra 4 ---
ROMEO:
And a the the will of is the he spaters,
I do dearthe come have the come of a mante
the shat and all hat is the of some the she sare some me
thand my his mast an the my stake the his as of and beat
A

--- muestra 5 ---
ROMEO:
What a shere the where the the be the of of the come.

LUCESTESTIO:
So she sor will be have packe he pron the dee his me
And mare wead her his me come a cand the my but and my
The seand mest here din
```

Configuración E Top p con p 0.95 y tau 1.0

```
=====
Config E -- top_p {'p': 0.95, 'tau': 1.0}
=====
--- muestra 1 ---
ROMEO:
Wer thy all not referear in sear bee cran hall.
And sime and thate reat is thee the do ens.

MERENIIZARLE:
OLA:
Harke my a as have hell yove chour what your come pall pre
To sow of wiscild lided;
Ama

--- muestra 2 ---
ROMEO:
Gir my strith here, nick the mes.

RUS:
Hese say, that a a of I murd peet to for me of I me.

DULERK:
And trasturs trust brim?
I'd Sand CHand my shatir thile no wauchsted rin heree
son of manke is th

--- muestra 3 ---
ROMEO:
Ay, thou pion of loulatt speirs my. Go,

Ciffues light.
Se that thou trou and fet amair I you.

THESNROM:
Cow.

ANOMYCHARSORY ICE:
That, we paich hindillam my yount bupar's the wind her
coure bus ing

--- muestra 4 ---
ROMEO:
For hist gries, lais pestorieso, thave afly ande,
tat ons in hare bothill upent sears?
Wath prer heatere intis sicess; oles so, bus has
me the hit mand will fortet tho ear why heeser ster;
And se co

--- muestra 5 ---
ROMEO: to and stall, a deay, to so betut
And you deincer'sior to godeid fid,
he bore ing in to and nomangecio wer,
Mut bete mirs wir herce: wast yome e anly heman.
Goff tou a dobestalled les ifion:
Hin sarv
```


Discusión de las muestras

Repetición en greedy

Las cinco muestras A son idénticas porque greedy aplica argmax en cada paso. Con el mismo prompt, la trayectoria completa es determinista. Cuando una continuación frecuente como the vuelve a producir un contexto parecido, el mismo máximo local reaparece y el modelo entra en ciclos. No existe muestreo estocástico que permita escapar de ese atractor.

Efecto de k y tau

En B, k igual a 5 restringe el soporte y tau igual a 0.7 amplifica las diferencias entre logits; por eso se conservan más palabras funcionales y estructuras reconocibles. En C, k igual a 50 permite muchos caracteres de baja probabilidad y tau igual a 1.0 deja una distribución menos concentrada. Las muestras C son más variadas y creativas, pero contienen más palabras inventadas. Según los resultados, B es más coherente y C es más diversa. Por ejemplo, B1 comienza 'ROMEO: There stere so the some a and a ther the thou ser I me the and hall a dower that the so the with s', mientras C1 comienza 'ROMEO: Pet swat this be fork'd col trove hey ne love Sine of lit. Cty pactee hews, and come'tur woulf ist'.

$$P(w_i | \text{contexto}) = \frac{\exp(z_i / \tau)}{\sum_j \exp(z_j / \tau)}$$

Adaptabilidad de top p

Los momentos de mayor confianza aparente incluyen secuencias ortográficas comunes como th, que se completan como the en las muestras E1, E2, E3, E4, y posiciones después de un encabezado terminado en dos puntos, donde suele aparecer un salto de línea (E1 después de MERENIIZARLE, E1 después de OLA, E2 después de RUS). En esos puntos, pocos caracteres concentran gran parte de la masa.

Los momentos de incertidumbre aparente incluyen la primera palabra después del prompt, que cambia entre E1 igual a 'Wer', E2 igual a 'Gir', E3 igual a 'Ay,', E4 igual a 'For', E5 igual a 'to', y los nombres o encabezados inventados, que varían ampliamente (E1 con MERENIIZARLE, E1 con OLA, E2 con RUS). En esas posiciones hay muchas continuaciones plausibles, de modo que el núcleo requerido para alcanzar p igual a 0.95 es más grande.

Task 3

Extracción con BERT

Oración	Objetivo	Sentido
El banco central anunció una subida de tasas de interés.	banco	financiero
Me senté en el banco del parque a leer el periódico.	banco	asiento
El banco de peces se movió velozmente ante el tiburón.	banco	peces
El equipo levantó la copa del torneo ante miles de aficionados.	copa	trofeo
Sirvió una copa de vino tinto para acompañar la cena.	copa	vino
El velero desplegó su vela para aprovechar el viento.	vela	barco
Encendió una vela para iluminar el cuarto durante el apagón.	vela	cera

Se usó bert base multilingual cased. Los offsets del tokenizador identifican los WordPieces que se solapan con la palabra objetivo; si existen varios subtokens, se promedian sus vectores de la última capa. No se usa el token CLS. Cada resultado tiene dimensión 768.

Similitud coseno de BERT

Palabra	Par de contextos	Similitud BERT
banco	banco-financiero vs banco-asiento	0.5753
banco	banco-financiero vs banco-peces	0.6603
banco	banco-asiento vs banco-peces	0.6496
copa	copa-trofeo vs copa-vino	0.5667
vela	vela-barco vs vela-cera	0.7999

$$\text{Similitud}(u, v) = \frac{u^T v}{||u|| ||v||}$$

Word2Vec preentrenado mediante gensim

Se cargó el modelo español SBWC en formato Word2Vec binario mediante gensim models KeyedVectors load word2vec format. Se limitaron los vectores leídos a los primeros 20,000, que incluyen las tres palabras objetivo y evitan materializar el modelo completo en memoria.

Palabra	Par de contextos	Word2Vec	BERT
banco	banco-financiero vs banco-asiento	1.0000	0.5753
banco	banco-financiero vs banco-peces	1.0000	0.6603
banco	banco-asiento vs banco-peces	1.0000	0.6496

copa	copa-trofeo vs copa-vino	1.0000	0.5667
vela	vela-barco vs vela-cera	1.0000	0.7999

Word2Vec produce 1.0000 en cada comparación porque asigna un único vector estático a cada palabra. BERT produce valores menores y diferentes entre pares, demostrando que su vector cambia con el contexto y puede codificar la ambigüedad semántica.

PCA en dos dimensiones




Figura 2. PCA de los siete embeddings; cada significado utiliza un color distinto.

Sentido	PC1	PC2
banco-financiero	6.745	-2.074
banco-asiento	7.159	0.472
banco-peces	4.991	-1.252
copa-trofeo	-3.267	5.426
copa-vino	-3.551	7.644
vela-barco	-6.088	-5.488
vela-cera	-5.989	-4.729

La identidad léxica domina la proyección: banco, copa y vela forman regiones separadas. Dentro de cada palabra existe dispersión entre sentidos, pero esa separación es menor que la distancia entre palabras diferentes. El PCA muestra una estructura semántica fina sin borrar la identidad de la palabra.

Task 4

Necesidad de la máscara causal

El objetivo autoregresivo factoriza la probabilidad de la secuencia como un producto de probabilidades condicionales. Para que cada probabilidad sea válida, la representación usada para predecir el token en t solo puede depender del prefijo anterior.

$$p(x_1, \dots, x_T) = \prod_{t=1}^T p(x_t | x_{<t})$$

La máscara causal coloca un valor negativo muy grande antes del softmax en las conexiones hacia posiciones futuras, haciendo que su peso de atención sea cero. Sin la máscara, una posición podría consultar durante el entrenamiento el token que debe predecir. La pérdida bajaría mediante fuga de información, pero esos tokens todavía no existirían en inferencia. El entrenamiento dejaría de medir una capacidad generativa real.

Preentrenar y adaptar

GPT y BERT optimizan objetivos distintos. GPT usa atención causal y es apropiado para generación autoregresiva. BERT usa atención bidireccional y construye representaciones que integran el contexto de ambos lados, por lo que resulta natural para clasificación, extracción de información y desambiguación.

Los resultados experimentales ilustran la diferencia: el Mini GPT genera carácter a carácter con perplejidad 7.650, mientras BERT asigna vectores distintos a una misma palabra según su sentido. Word2Vec no puede hacerlo y siempre compara el mismo vector consigo mismo. El paradigma de preentrenar y adaptar permite seleccionar el backbone adecuado y especializarlo mediante fine tuning, prompting o una cabeza nueva, sin entrenar desde cero.

Repositorio

REPOSITORIO

GITHUB

